

인간대상연구 피험자 동의서

기본 정보				
승인번호	KAISTIRB-2026-203			
연구 과제명	인간의 도구 선택 모델링: 에이전트 기반 시뮬레이션을 통한 모더레이션 시나리오 분석			
연구 책임자	성명	소속	직위	전공분야
	Joseph Seering	School of Computing	Associate Professor	Computer Science
	전화번호 : 042-350-7789 팩스: 010-8682-5702 이메일: seering@kaist.ac.kr			

※본 연구에 대한 문의사항이 있으시거나 동의서에 표기된 위험이나 불편감이 생기는 경우, 또는 연구와 관련된 손상이 발생할 경우, 위의 연구자에게 연락하여 주시기 바랍니다.

※기타 문의 및 상담 : KAIST 생명윤리심의위원회 행정간사(Tel 042-350-2189)

1. 본 연구는 오로지 연구만을 목적으로 수행됩니다.

2. 연구의 배경 및 목적

모더레이션 도구란 소셜 미디어 플랫폼, 모더레이터, 그리고 일반 사용자가 온라인에서 안전하고 건강한 상호작용을 보장하기 위해 사용하는 도구입니다. 모든 플랫폼은 사용자에게 최소한의 기본적인 모더레이션 도구를 제공하지만, 이것이 실제로 사용자를 보호하기에 항상 충분한 것은 아닙니다. 2021년 트위치 혐오 레이드(Twitch Hate Raids) 사례에서는 대규모 계정들이 사용자 스트리밍 채널을 혐오 콘텐츠로 침범하였으며, 특히 취약 커뮤니티 출신의 스트리머들이 집중적인 표적이 되었습니다 [1]. 기존 모더레이션 도구들은 이를 감당하지 못했고, 플랫폼의 대응은 지연되었으며 [1], 결국 사용자들이 자신의 커뮤니티를 보호하기 위해 직접 제3의 도구를 제작하고 공유해야 했습니다 [1, 2]. 이 사례는 플랫폼이 제공하는 모더레이션 도구가 사용자에게 실질적으로 충분한지 이해할 필요가 있음을 잘 보여줍니다. 그러나 이는 플랫폼에 따라 크게 달라지는 복잡한 문제로, 단일한 답이 존재하지 않으며, 플랫폼이 실제 사용자를 대상으로 직접 검증을 수행해야 합니다.

선행 연구에 따르면, 다양한 피해 유형, 커뮤니티 맥락, 사용자 성격의 전체 범위에 걸쳐 실제 사용자를 대규모로 연구하는 것은 비용과 시간 측면에서 현실적으로 어렵습니다[3]. AI 에이전트를 인간 응답자의 대리인으로 활용하는 방식이 설문 및 행동 연구에서 대안으로 탐색되어 왔으나[3, 4], 단순히 AI 모델에게 "일반적인 사용자"로 응답하도록 지시하는 방식은 실제 모더레이션 행동을 특징짓는 개인 간 차이를 평탄화시킵니다. 사용자들은 어떤 도구가 존재하는지에 대한 인식, 모더레이션과 관련된 개인적 경험, 그리고 성격 면에서 서로 다르며, 이 모든 요소가 그들이 선택하는 도구에 영향을 미칩니다. 본 연구의 핵심 문제를 다루기 위해서는 특정 모더레이션 시나리오 하에서 사용자가 어떤 도구를 선택할지를 적절히 모델링할 필요가 있습니다. 본 연구는 세 가지 구성 요소로 이루어진 아키텍처를 통해 개별 사용자의 인지를 모델링하는 구조화된

접근 방식을 취합니다. 구체적으로는 의미 기억(사용 가능한 도구에 대한 지식, 도구별 인지 점수, 사용자 성격 등), 일화 기억(개인적인 모더레이션 이력 및 과거 경험), 그리고 작업 기억(이러한 입력을 통합하여 도구 선택을 도출하는 능동적 추론 단계)으로 구성됩니다. 아키텍처 구축에 필요한 세부 정보는 참가자를 대상으로 한 설문 사용자 연구를 통해 수집됩니다. 참가자들은 제시된 특정 모더레이션 시나리오에서 사용할 도구를 목록에서 직접 선택하게 되며, 이렇게 수집된 정보를 바탕으로 구축된 에이전트가 동일한 시나리오에서 유사한 도구를 선택하는지를 비교함으로써 에이전트의 타당성을 검증합니다.

- [1] Catherine Han, Joseph Seering, Deepak Kumar, Jeffrey T. Hancock, and Zakir Durumeric. 2023. Hate Raids on Twitch: Echoes of the Past, New Modalities, and Implications for Platform Governance. *Proc. ACM Hum. Comput. Interact.* 7, CSCW1, Article 133 (April 2023), 28 pages. <https://doi.org/10.1145/3579609>
- [2] Meisner, Colten. "Networked responses to networked harassment? Creators' coordinated management of "hate raids" on Twitch." *Social Media+ Society* 9.2 (2023): 20563051231179696.
- [3] Hämäläinen, Perttu, Mikke Tavast, and Anton Kunnari. "Evaluating large language models in generating synthetic hci research data: a case study." *Proceedings of the 2023 CHI conference on human factors in computing systems*. 2023.
- [4] Argyle, Lisa P., et al. "Out of one, many: Using language models to simulate human samples." *Political Analysis* 31.3 (2023): 337-351.

3. 예상 참여기간 및 본 시험에 참여하는 대략의 전체 피험자 수

본 연구의 예상 참여 기간은 2026년 7월 1일부터 2027년 5월 30일까지입니다. 전체 연구 소요 시간은 약 80분으로 예상됩니다. 중도 탈락률을 고려하여 총 150명의 참가자를 모집할 예정입니다.

4. 본 연구에 참여하게 됨으로써 받게 되는 검사 및 절차

본 연구는 온라인 설문 형태로 진행되며, 약 80분에 걸쳐 다섯 단계로 구성됩니다.


1단계 (10분): 참가자들은 사전 동의서를 통해 연구 개요를 안내받으며, 원하는 경우 언제든지 연구에서 철회할 수 있는 권리가 있음을 명확히 고지받습니다. 또한 도구 선택에 미치는 영향을 파악하기 위해 나이, 성별 등 기본적인 인구통계 정보를 수집합니다.

2단계 (10분): 참가자들은 빅 파이브 성격 특성 검사(BFI-2-S)[6]를 완료합니다. 이 검사는 성격 특성에 관한 30개의 문항으로 구성되며, 참가자는 각 문항에 대해 1점(전혀 해당되지 않음)부터 5점(매우 해당됨)까지의 척도로 평가합니다. 참가자들은 또한 모더레이션 시나리오에서 도구를 선택할 때 추구하는 바와 가장 일치하는 옵션을 선택하는 방식으로, 모더레이션에 대한 관점을 묻는 5개의 질문에 답합니다.

3단계 (10분): 참가자들은 연구에 포함된 15개의 모더레이션 도구의 이름과 설명을 소개받고, 해당 도구들을 이전에 접한 적이 있는지 응답합니다.

4단계 (25분): 참가자들은 소셜 미디어 플랫폼에서 수집한 실제 게시물 20개를 제공받습니다. 각 게시물에 대해 15개 도구 중 연구자가 제공하는 4개의 도구 중에서 가장 적절한 모더레이션 대응을 선택하고, 간략한 선택 이유를 작성합니다.

5단계 (25분): 참가자들은 선행 연구에서 정의된 피해 분류 체계에 따라 연구자들이 설계한 20개의 시나리오를 대상으로 동일한 과제를 수행합니다 [7]. 동일한 응답 형식이 적용됩니다.



[5] Banko, Michele, Brendon MacKeen, and Laurie Ray. "A unified taxonomy of harmful content." Proceedings of the fourth workshop on online abuse and harms. 2020.

[6] 6] Sirui Wang, Weitao Jiang, Xuesong Zhang, Guo Freeman, and Seungwoo Je. 2026. "Similar-Self" vs. "Alt-Self": How Avatar Customization Impacts Trust Formation in Social VR and Its Transfer to Face-to-Face between Unacquainted Individuals. In Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems (CHI &26), April 13-17, 2026, Barcelona, Spain. ACM, New York, NY, USA, 25 pages. <https://doi.org/10.1145/3772318.3790833>

5. 본 연구에 참여함으로써 피험자(피험자가 임부일 경우 태아, 수유부일 경우 영유아)에게 미칠 것으로 예견되는 위험(부작용)이나 불편사항

본 연구는 최소한의 위험만이 예상되며, 안전과 관련한 중대한 우려 사항은 없습니다.

본 연구는 전적으로 온라인으로 진행되며, 참가자들은 개인 기기를 사용하여 설문을 완료합니다. 참여와 관련된 신체적 안전 위험은 없습니다. 다만, 4단계에서 참가자들은 불편한 콘텐츠가 포함될 수 있는 실제 소셜 미디어 게시물에 노출될 수 있습니다. 이를 완화하기 위해 4단계의 모든 콘텐츠는 배포 전 연구팀이 검토하여 유해한 표현을 검열합니다.

참가자가 실험 도중 불편함을 느껴 중단을 원할 경우, 실험은 즉시 중단됩니다. 데이터 수집 과정에서 수집된 모든 개인 정보는 익명화되거나 삭제됩니다. 수집되는 데이터는 인구통계 정보(나이, 성별), 설문 응답, 도구 선택 결과, 그리고 선택 이유입니다. 수집된 정보는 연구 결과에 대한 집계 및 분석을 통한 인사이트 도출 목적으로만 사용되며, 개인을 식별하거나 특정 참가자를 식별하는 데 사용되지 않습니다. 또한 연구 참여 보상 지급을 위해 이름, 생년월일, 연락처, 은행명 및 계좌번호가 수집되며 KAIST 외부인의 경우 주민등록번호와 주소가 추가로 수집됩니다. 해당 정보 역시 지급 처리 목적에만 사용됩니다. 수집된 모든 정보는 연구 종료 후 2개월 이내에 안전하게 폐기됩니다. 참가자는 언제든지 연구 참여 철회를 요청할 수 있습니다.

6. 이 연구에 참여함으로써 기대되는 이익

본 연구에 참여하시면 50,000원의 금전적 보상을 받으실 수 있습니다. 참가자들의 노력은 연구 완료 후 소셜 미디어 공간에서 보다 나은 모더레이션 도구 지원을 제공하는 데 활용되며, 소셜 미디어의 모더레이션 도구 공간에서의 공백을 파악하는 데에도 사용될 수 있습니다.

7. 신분의 비밀보장 및 개인정보 보호(자료의 열람 권한 설정 및 보관, 관리, 폐기, 임상시험 결과 발표 시 피험자의 신원 보호)

데이터 수집 과정에서 수집된 모든 개인 정보는 익명화되거나 삭제됩니다. 수집되는 데이터는 인구통계 정보(나이, 성별), 설문 응답, 도구 선택 결과, 그리고 선택 이유입니다. 수집된 정보는 연구 결과에 대한 집계 및 분석을 통한 인사이트 도출 목적으로만 사용되며, 개인을 식별하거나 특정 참가자를 식별하는 데 사용되지 않습니다. 또한 연구 참여 보상 지급을 위해 이름, 생년월일, 연락처, 은행명 및 계좌번호가 수집되며 KAIST 외부인의 경우 주민등록번호와 주소가 추가로 수집됩니다. 해당 정보 역시 지급 처리 목적에만 사용됩니다. 수집된 모든 정보는 연구 종료 후 2개월 이내에 안전하게 폐기됩니다. 참가자는 언제든지 연구 참여 철회를 요청할 수 있습니다.

7-1. 개인정보 수집에 대한 사항 동의(해당시 / 텍스트 크기 변경 금지)

■ 개인정보의 수집.이용 목적 : 나이, 성별, 성격 검사 결과, 도구 선택 결과, 선택 이유 등 실험 중 수집된 데이터는 이러한 요소들이 모더레이션 결과에 미치는 영향에 대한 통찰을 도출하는 목적으로만 사용되며, 연구 종료 후 2개월 뒤 폐기됩니다.

■ 수집.이용하려는 개인정보의 항목 : 나이, 성별, 성격 검사 결과, 도구 선택 결과, 선택 이유

■ 개인정보의 보유 및 이용기간 : 연구종료 후 2월간 보관 후 폐기

본 연구에서 참여함으로써 수집되는 개인정보는 위 항목과 같으며, 해당 정보는 보존 기간내에만 보존하며, 타 연구자에게 제공되지 않습니다. 귀하의 동의에 따라 개인정보는 수집하지 않을 수 있으며, 동의를 거부할 경우 아래와 같이 불이익이 있을 수 있습니다.

■ 미동의시 불이익 내용 : 개인정보 수집에 동의하지 않는 참가자는 연구 참여에 대한 보상을 받을 수 없습니다.

본인은 개인정보 수집에 대한 내용을 확인하였으며, 본 연구에서 개인정보 수집에 대하여

▶ 동의합니다/ I agree to collection and use of personal data. ()

▶ 동의하지 않습니다/ I don't agree. ()

7-2. 개인정보의 제공에 관한 사항

본 연구에서 참여함으로써 수집되는 개인정보는 성명, 생년월일, 은행명, 계좌번호이며, KAIST 외부인의 경우 주민등록번호와 주소가 추가로 수집됩니다. 해당 정보는 귀하의 동의에 따라 보존 기간내 2차적 사용을 위해 제공될 수 있습니다. 연구자는 타연구자에게 개인정보제공을 제공하는 경우에는 KAIST 생명윤리심의위원회에 개인정보제공에 관하여 별도 심의를 받아야 합니다.

▶ 유사한 연구 범위 안에서만 제공하는 것에 동의합니다./ Consent to sharing within scope of similar study ()

▶ 포괄적 연구 목적으로 제공하는 것에 동의합니다./ Consent for general research purposes ()

▶ 동의하지 않습니다./ Do not consent ()

귀하가 개인정보제공에 대하여 동의시, 해당 정보는 익명화하여 제3자에게 제공되어집니다. 다만, 귀하가 개인식별정보를 포함하는 것에 동의한 경우에는 예외로 합니다.

▶ 개인식별정보를 포함하는 것에 동의합니다. I consent to personally identifiable data inclusion ()

▶ 동의하지 않습니다. /I don't consent ()

8. 연구와 관련된 손상이 발생하였을 경우 피험자에게 주어질 보상이나 치료방법

본 연구는 온라인 설문으로 진행되며 신체적 위험은 없으나, 4단계에서 불쾌한 콘텐츠로 인한 심리적 불편함이 발생할 수 있습니다.

심리적 불편함이 발생할 경우, 참가자는 언제든지 즉시 실험을 중단할 수 있으며 어떠한 불이익도 없습니다.

피해가 발생할 경우 연구자들이 상담 자원 및 지원 정보를 제공합니다.

9. 피험자가 연구의 참가에 동의하지 않더라도 불이익이나 차별을 받지 않는다는 것 / 피험자가 자발적으로 연구의 참가를 동의한 경우라도 자유의사에 의해 언제든지 이를 철회할 수 있다는 내용(단, 이와 같은 철회가 시험 개시 이전에 이루어지고 연구참가에 대한 보상이 있었던 경우 보상금의 반환 여부)

연구 참여 여부에 대한 최종 결정은 참가자 본인이 내립니다. 언제든지 연구 참여를 거부하거나 철회할 수 있습니다. 본 연구 참여를 거부하더라도 어떠한 불이익도 없으며, 이 결정이 향후 연구 참여에 영향을 미치지 않습니다. 수집된 데이터는 폐기됩니다.

10. 연구에 사용되는 의약품(또는 기구)은 어떤 약(또는 기구)이며 시험군 또는 대조군에 무작위로 배정될 확률

해당되지 않음

11. 본 연구를 위해 피험자가 준수해야 하는 사항

악의적인 의도를 가진 관련 없는 응답은 허용되지 않습니다. 연구자가 참가자가 실험 데이터를 조작하거나 오염시키려는 시도를 발견할 경우, 해당 데이터는 폐기됩니다.

12. 본 연구의 검증되지 않은 실험적인 측면

LLM 에이전트가 실제 사용자 페르소나 데이터(성격 프로필, 모더레이션 철학, 도구 사용 경험)를 기반으로 구축되어 인간의 모더레이션 도구 선택 행동을 재현할 수 있는지에 대한 검증은 아직 이루어지지 않았습니다.

에이전트의 다양한 기억 구조는 선행 연구에서 제안된 바 있습니다. 그러나 의미 기억, 일화 기억, 작업 기억으로 구성된 세 가지 인지 아키텍처를 통해 개별 사용자의 도구 선택 패턴을 시뮬레이션하는 접근 방식은 콘텐츠 모더레이션 분야에서 새롭게 시도되는 방법입니다.

13. (실험이 질병의 치료와 관련이 있을 경우) 이 질환으로 선택할 수 있는 다른 치료방법 및 이러한 치료의 잠재적 위험과 이익

해당되지 않음

14. 연구에 참여함으로써 받게 되는 금전적 보상 유무 및 참여정도에 따른 조정 정도 및 연구에 참여함으로써 피험자에게 추가적으로 발생이 예상되는 비용

연구 참여에 대한 금전적 보상으로, 참가자는 90분간의 사용자 연구 참여에 대해 소정의 보상금 50,000원을 지급받습니다.

15. 연구의 지속 참여 의지에 영향을 줄 수 있는 새로운 정보가 얻어지면 적시에 피험자 본인 또는 대리인에게 알려드릴 것입니다.

16. 연구진이 필요하다고 판단할 경우, 본인의 동의 없이도 본 연구 참여에서 제한될 수 있습니다. 또한 이 경우 연구책임자 또는 동의서상에 명시된 연구자에게 통보함으로써 본 연구에서 불참할 수 있습니다.

17. 본 연구진행 중 본인에게 영향을 줄 수도 있는 새로운 정보를 연구자가 획득 시 그 내용을 통보 받을 수 있습니다.

▶ 통보를 원합니다/Notify me about research updates. ()

▶ 통보를 원치 않습니다./Do not notify me ()

18. 연구에 대한 추가적인 정보를 얻고자 하거나 연구와 관련이 있는 손상이 발생한 경우에 접촉해야 하는 사람과 연락처

(예시) 본 연구의 참여와 관련하여 문의 및 불만 사항이 있으신 경우에는 언제든지 연구진에게 연락하여 주시기 바랍니다.

<연구자 성명: Braahmi Padmakumar, 연락처 (☎) 010-9743-6683>

본인은 이 동의서를 읽고 이해하였으며 모든 질문에 대한 답변을 들었습니다. 이에 본인은 자발적으로 본 연구에 참여함을 서명으로 확인합니다.

또한, 본인은

1. 본인과 연구자 및 KAIST 사이에 본인의 연구 참여결정에 영향을 줄 수 있는 어떠한 관계도 없고,
2. 요양원 같은 수용 시설에 거주하거나, 인지 기능에 문제가 있지 아니하며,
3. 만약, 위에 열거한 1, 2의 상황에 해당되는 경우 생명윤리심의위원회 간사의 입회하에 본 동의서에 대한 설명을 듣고 아래 서명을 하였음을 확인합니다.

피험자

(만 18세 미만인 경우 법정대리인이 아래 서명하고 미성년자의 이름을 여기에 적으며 : _____)

미성년자가 동의내용을 이해하는 경우 여기에 미성년자도 서명함 : _____)

주소 (Address) /

연락처 (Contact No.)/

성명 (Name)/

(서명 또는 인/Sign)

동의일자 (Date) /

동의서 설명자

성명 / Braahmi Padmakumar

(서명 또는 인)

본인은 생명윤리심의위원회 간사로서 상기 피험자가 동의서 설명자로부터 동의서에 대한 충분한 설명을 듣고 아무런 강압 없이 전적으로 자발적으로 동의서를 작성하였음을 확인합니다.

생명윤리심의위원회 간사

성명 /

(서명 또는 인)

연구책임자

성명 Joseph Seering

(서명 또는 인)

